

# Assignment Guidance: Exploring Clustering Techniques with Python

Data Science dan Data Analyst Bootcamp

## Periode Pembelajaran

Introduction to Unsupervised Machine Learning Models with Python

Exploring Clustering Techniques with Python

## Objectives

1. Student mampu melakukan data preprocessing dengan menggunakan Python untuk mempersiapkan dataset.
2. Student mampu melakukan Exploratory Data Analysis (EDA) untuk memahami pola dan distribusi data.
3. Student mampu membuat model K-Means Clustering untuk mengelompokkan pelanggan berdasarkan data perjalanan mereka.
4. Student mampu melakukan visualisasi hasil clustering menggunakan grafik yang sesuai untuk mempermudah interpretasi.
5. Student mampu melakukan interpretasi model dan hasil clustering untuk menemukan insight yang berguna.
6. Student mampu melakukan evaluasi model clustering menggunakan metrik seperti Silhouette Score.
7. Student mampu melakukan analisis setiap cluster dan memberikan rekomendasi bisnis berdasarkan hasil analisis tersebut.

## Deskripsi Assignment

Dalam assignment ini, student akan melakukan segmentasi pelanggan menggunakan teknik K-Means Clustering. Sebagai Data Scientist di sebuah perusahaan penerbangan, student diminta untuk mengelompokkan pelanggan berdasarkan pola perjalanan mereka, serta memberikan rekomendasi bisnis berdasarkan hasil segmentasi tersebut.

Tujuan utama dari tugas ini adalah untuk membantu student memahami cara membuat model clustering menggunakan K-Means, mengoptimalkan jumlah cluster yang tepat, serta memberikan wawasan bisnis yang berguna dari hasil clustering tersebut.

## Detail Assignment

Link Dataset: [Flight](#)

| Code | Description |
|------|-------------|
|------|-------------|

|                   |                                                                        |
|-------------------|------------------------------------------------------------------------|
| MEMBER_NO-b       | : ID Member                                                            |
| FFP_DATE          | : Frequent Flyer Program Join Date                                     |
| FIRST_FLIGHT_DATE | : Tanggal Penerbangan pertama                                          |
| GENDER            | : Jenis Kelamin                                                        |
| FFP_TIER          | : Tier dari Frequent Flyer Program                                     |
| WORK_CITY         | : Kota Asal                                                            |
| WORK_PROVINCE     | : Provinsi Asal                                                        |
| WORK_COUNTRY      | : Negara Asal                                                          |
| AGE               | : Umur Customer                                                        |
| LOAD_TIME         | : Tanggal data diambil                                                 |
| FLIGHT_COUNT      | : Jumlah penerbangan Customer                                          |
| BP_SUM            | : Rencana Perjalanan                                                   |
| SUM_YR_1          | : Total credit/point di tahun pertama                                  |
| SUM_YR_2          | : Total credit/point di tahun kedua                                    |
| SEG_KM_SUM        | : Total jarak(km) penerbangan yg sudah dilakukan                       |
| LAST_FLIGHT_DATE  | : Tanggal penerbangan terakhir                                         |
| LAST_TO_END       | : Jarak waktu penerbangan terakhir ke pesanan penerbangan paling akhir |
| AVG_INTERVAL      | : Rata-rata jarak waktu                                                |
| MAX_INTERVAL      | : Maksimal jarak waktu                                                 |
| EXCHANGE_COUNT    | : Jumlah penukaran                                                     |
| avg_discount      | : Rata rata discount yang didapat customer                             |
| Points_Sum        | : Jumlah poin yang didapat customer                                    |
| Point_NotFlight   | : point yang tidak digunakan oleh members                              |

Untuk menyelesaikan assignment ini, **student harus mengikuti langkah-langkah berikut:**

### 1. Data Preprocessing

- Import library yang dibutuhkan: **numpy, pandas, seaborn, matplotlib, sklearn.**
- Muat dataset yang telah disediakan dan lakukan **pembersihan data**, termasuk menangani **missing values** dan **feature selection**.
- Pastikan dataset siap digunakan untuk analisis clustering.

### 2. Exploratory Data Analysis (EDA)

- Lakukan **analisis statistik deskriptif** terhadap dataset.
- Visualisasikan distribusi data numerik dan hubungan antar fitur menggunakan **scatter plot** atau **heatmap**.
- Identifikasi pola dalam data yang mungkin mempengaruhi hasil clustering.

### 3. Clustering dengan K-Means

- Gunakan metode **K-Means Clustering** untuk membagi pelanggan ke dalam beberapa kelompok (cluster).
- Tentukan jumlah cluster yang optimal dengan menggunakan metode seperti **Elbow Method** atau **Silhouette Score**.

#### 4. Visualisasi Hasil Clustering

- Gunakan **scatter plot** atau metode visualisasi lainnya untuk menampilkan hasil clustering.
- Pastikan visualisasi dapat menunjukkan perbedaan antar cluster secara jelas.

#### 5. Evaluasi Model

- Gunakan metrik seperti **Silhouette Score** untuk mengevaluasi hasil clustering.
- Bandingkan hasil clustering dengan jumlah cluster yang berbeda untuk menemukan model yang paling optimal.

#### 6. Insight dan Rekomendasi

- Analisis setiap cluster dan identifikasi **karakteristik unik** dari masing-masing kelompok pelanggan.
- Berikan rekomendasi bisnis berdasarkan hasil analisis cluster, misalnya strategi pemasaran atau retensi pelanggan.

### Ekspektasi Output

Student harus mengumpulkan link **Google Colaboratory** yang berisi:

- **Script Python** untuk seluruh langkah-langkah di atas.
- **Visualisasi grafik** yang menunjukkan hasil clustering dan karakteristik setiap cluster.
- **Dokumentasi dalam bentuk markdown atau teks** yang menjelaskan:
  - Langkah-langkah analisis
  - Model K-Means yang digunakan
  - Hasil evaluasi dan interpretasi dari setiap cluster.

### Tools

Google Colaboratory

### Pengumpulan Assignment

#### Deadline :

Maksimal H+7 Kelas (Pukul 23.30 WIB)

#### Details :

Dikumpulkan dalam bentuk Link Google Colaboratory, secara INDIVIDU, di LMS

## Indikator Penilaian

| No. | Aspek Penilaian         | Parameter                                                                          | Bobot Maksimal |
|-----|-------------------------|------------------------------------------------------------------------------------|----------------|
| 1   | Data Preprocessing      | Student mampu melakukan pembersihan data, feature selection, dan persiapan dataset | 25             |
| 2   | Clustering              | Student mampu menerapkan metode K-Means dengan jumlah cluster yang optimal         | 25             |
| 3   | Visualisasi Data        | Student mampu menampilkan hasil clustering dalam bentuk grafik                     | 25             |
| 4   | Insight dan Rekomendasi | Student mampu menganalisis hasil clustering dan memberikan rekomendasi bisnis      | 25             |

## Referensi/Template

1. [Data Science: 6th International Conference of Pioneering Computer Scientists](#)
2. <https://drive.google.com/drive/folders/1R2zzE8cTf-JwNzP-orxaGDWoQGh2qmAy>
3. <https://ieeexplore.ieee.org/document/9736735>
4. <https://ieeexplore.ieee.org/document/9967896>

### Ketentuan Pencapaian Nilai:

Nilai minimum Lulus Penyaluran Kerja: 75

Nilai minimum Lulus Bootcamp: 65

### Ketentuan Penilaian:

Mengumpulkan Assignment tepat waktu: Sesuai dengan nilai yang diberikan mentor

Mengumpulkan Assignment 12 jam setelah deadline: - 3 dari nilai yang diberikan mentor

Mengumpulkan Assignment 1 x 24 Jam setelah deadline: - 6 dari nilai yang diberikan mentor

Mengumpulkan Assignment 2 x 24 Jam setelah deadline: - 12 dari nilai yang diberikan mentor

Mengumpulkan Assignment 3 x 24 Jam setelah deadline: - 18 dari nilai yang diberikan mentor

Mengumpulkan Assignment 4 x 24 Jam setelah deadline: - 24 dari nilai yang diberikan mentor

Mengumpulkan Assignment 5 x 24 Jam setelah deadline: - 30 dari nilai yang diberikan mentor

Mengumpulkan Assignment 6 x 24 Jam setelah deadline: - 36 dari nilai yang diberikan mentor

Mengumpulkan Assignment 7 x 24 Jam setelah deadline: - 42 dari nilai yang diberikan mentor