

Introduction to Unsupervised Machine Learning Models with Python

Batch 33B | Bootcamp Data Science &
Data Analyst





Nikmatun Aliyah Salsabila

Mentor

Data Scientist

LinkedIn:

[linkedin.com/in/nasalsabila](https://www.linkedin.com/in/nasalsabila)

- **Data Scientist**
at Multidaya Teknologi Nusantara
- **Data Analyst**
at Airy Nest Indonesia

A large black parallelogram is positioned on the left side of the slide. Below it, two overlapping parallelograms in shades of orange and yellow are also positioned on the left, creating a layered, abstract geometric design.


Unsupervised Learning

Apa itu Unsupervised Learning?

Unsupervised Machine Learning adalah cabang *machine learning* di mana algoritma belajar dari **data tanpa label** (*unlabeled data*). Artinya, tidak ada target *output* yang eksplisit. Tujuannya adalah menemukan pola tersembunyi, struktur intrinsik, atau hubungan dalam data itu sendiri secara mandiri.

Apa bedanya dengan Supervised Learning?

- *Supervised learning* seperti mengajarkan anak mengenal kucing dengan menunjukkan banyak gambar kucing berlabel "kucing".
- *Unsupervised learning* seperti memberikan banyak gambar hewan kepada anak dan memintanya mengelompokkan gambar-gambar tersebut berdasarkan kemiripan, tanpa diberitahu mana kucing, anjing, atau burung.



Contoh Aplikasi Unsupervised Learning

- **Clustering (*Pengelompokan*)**: Mengelompokkan titik data yang serupa ke dalam grup atau "klaster". Contoh: Segmentasi pelanggan untuk strategi pemasaran yang lebih baik, mengelompokkan dokumen berdasarkan topik, deteksi anomali.
- **Association (*Aturan Asosiasi*)**: Menemukan hubungan atau pola di antara variabel-variabel dalam dataset besar. Contoh: Analisis keranjang belanja (misalnya, orang yang membeli roti sering juga membeli selai).
- **Dimensionality Reduction (*Reduksi Dimensi*)**: Mengurangi jumlah fitur (*features*) atau variabel dalam dataset sambil tetap mempertahankan informasi penting. Contoh: Kompresi gambar, visualisasi data kompleks, atau mengatasi **kutukan dimensi** (*curse of dimensionality*).

A large black parallelogram is positioned on the left side of the slide. Below it, two overlapping parallelograms in light orange and a darker orange shade are also positioned on the left, partially overlapping the black shape.

Dimensionality Reduction

Dimensionality Reduction

Dimensionality Reduction adalah proses **mengubah data** dari ruang dengan banyak fitur (**high-dimensional space**) menjadi ruang dengan fitur yang lebih sedikit (**low-dimensional space**).

Mengapa butuh dimensionality reduction?

Saat jumlah fitur dalam dataset meningkat, volume ruang data bertambah secara eksponensial. Ini membuat data menjadi sangat jarang (*sparse*) di ruang dimensi tinggi, sebuah fenomena yang dikenal sebagai kutukan dimensi (**curse of dimensionality**).

Dampak Curse of Dimensionality

- **Peningkatan beban komputasi:** Algoritma menjadi lebih lambat dan membutuhkan lebih banyak memori.
- **Kesulitan visualisasi:** Sangat sulit memvisualisasikan data dalam lebih dari tiga dimensi.
- **Kinerja model buruk (*Overfitting*):** Di dimensi tinggi, model cenderung menemukan pola palsu dalam data latih yang tidak mampu digeneralisasi dengan baik ke data baru, menyebabkan *overfitting*.
- **Kebutuhan data lebih banyak:** Untuk menjaga kepadatan data yang sama, jumlah data yang dibutuhkan meningkat secara eksponensial seiring dengan peningkatan dimensi.

Manfaat Dimensionality Reduction

- Mengurangi risiko *overfitting*
- Mempercepat pelatihan algoritma *machine learning*
- Meningkatkan kemampuan visualisasi data
- Mengurangi kebutuhan penyimpanan data
- Membantu interpretasi data dengan mengidentifikasi fitur-fitur penting

A large black parallelogram is positioned on the left side of the slide. Below it, two overlapping parallelograms in shades of orange and yellow are also positioned on the left, creating a layered effect.


Principal Component Analysis (PCA)

Apa itu PCA?

- PCA adalah teknik *dimensionality reduction* linier yang mengubah data asli menjadi sistem koordinat baru.
- Setiap sumbu baru ini disebut **Principal Component** (PC), dan masing-masing PC menangkap varians terbesar dalam data.
- PC-PC ini juga bersifat ortogonal (*orthogonal*), artinya saling tegak lurus.
- Tujuan PCA adalah menemukan arah (vektor) di mana data paling banyak menyebar (memiliki varians terbesar) dan memproyeksikan data ke arah tersebut.

Intuisi PCA: Step-by-step


Kita akan menggunakan **dataset Iris** dan hanya memilih 3 fitur (**sepal length (cm)**, **petal length (cm)**, dan **petal width (cm)**) agar mudah divisualisasikan dalam 3D. Fitur-fitur ini terkait dengan dimensi bunga Iris.



	sepal length (cm)	petal length (cm)	petal width (cm)
0	5.1	1.4	0.2
1	4.9	1.4	0.2
2	4.7	1.3	0.2
3	4.6	1.5	0.2
4	5.0	1.4	0.2

Step 1: Standardisasi Data

PCA sangat sensitif terhadap skala fitur. Fitur dengan rentang nilai yang jauh lebih besar akan mendominasi *principal component*. **Standardisasi** (membuat rata-rata menjadi 0 dan standar deviasi menjadi 1) memastikan setiap fitur berkontribusi setara dalam analisis.



	sepal length (cm)	petal length (cm)	petal width (cm)
0	-0.900681	-1.340227	-1.315444
1	-1.143017	-1.340227	-1.315444
2	-1.385353	-1.397064	-1.315444
3	-1.506521	-1.283389	-1.315444
4	-1.021849	-1.340227	-1.315444

Step 2: Menghitung Covariance Matrix


Covariance matrix (C) dari data yang sudah distandardisasi menunjukkan seberapa banyak setiap pasangan variabel berubah bersama. Ini adalah *blueprint* dari bagaimana data tersebar dan terhubung, yang akan menjadi dasar untuk menemukan arah varians terbesar.

Covariance matrix dari dataset Iris yang sudah distandardisasi:

```
[[1.00671141 0.87760447 0.82343066]
```

```
[0.87760447 1.00671141 0.96932762]
```

```
[0.82343066 0.96932762 1.00671141]]
```



Step 3: Menghitung Eigenvalues dan Eigenvectors (Principal Components)


Ini adalah inti dari PCA. Kita mencari arah (vektor) atau *eigenvector* (yang akan menjadi *Principal Component*) dan skalar (lambda) atau *eigenvalue* yang memenuhi persamaan: $\Sigma \mathbf{v} = \lambda \mathbf{v}$

Eigenvector (Principal Component): Arah-arrah (garis) di mana data paling banyak bervariasi. Mereka saling tegak lurus (*orthogonal*).

Eigenvalue: Nilai yang terkait dengan setiap *eigenvector*. *Eigenvalue* menunjukkan "kekuatan" atau "varians" yang dijelaskan oleh *eigenvector* tersebut. Semakin besar *eigenvalue*, semakin banyak varians yang dijelaskan oleh *Principal Component* yang bersangkutan.

Step 3: Menghitung Eigenvalues dan Eigenvectors (Principal Components)


Data Iris Terstandarisasi dengan Principal Components (Eigenvectors)




Step 4: Memilih Principal Components

- Setelah menghitung semua PC dan *eigenvalue*-nya, kita perlu memutuskan berapa banyak PC yang akan dipertahankan. Tujuannya adalah mengurangi dimensi sambil mempertahankan sebagian besar informasi (varians).
- Alat: **Scree Plot** menunjukkan *eigenvalue* untuk setiap PC dalam urutan menurun. Kita mencari "siku" (*elbow point*) pada plot, di mana penurunan varians yang dijelaskan mulai melambat secara signifikan. Titik ini seringkali menjadi indikasi jumlah PC yang optimal.

Scree Plot (Proporsi Varians Dijelaskan) untuk Iris




Kumulatif Scree Plot untuk Iris




Step 5: Memproyeksikan Data ke Ruang Dimensi Baru


Langkah terakhir adalah memproyeksikan data yang sudah distandardisasi ke *Principal Component* yang telah kita pilih. Ini adalah transformasi linier yang mengubah koordinat data dari sistem koordinat asli ke sistem koordinat baru yang dibentuk oleh PC.



from this



to this



A large black parallelogram is positioned on the left side of the slide. Below it, two overlapping parallelograms in shades of orange and yellow are also positioned on the left, creating a layered, abstract geometric design.

Factor Analysis (FA)

Factor Analysis

- **Factor Analysis (FA)** adalah teknik statistik yang digunakan untuk **menemukan struktur tersembunyi (faktor laten)** di balik sekumpulan variabel yang saling **berkorelasi**.
- FA didasarkan pada ide bahwa **korelasi yang kita lihat antar variabel-variabel teramati adalah akibat dari pengaruh satu atau lebih faktor laten yang mendasari**. Jika variabel A dan variabel B sangat berkorelasi, FA berasumsi ada "sesuatu" (faktor laten) yang menyebabkan keduanya bergerak bersamaan.
- FA merupakan metode statistik yang sangat kuat terutama di bidang psikologi, sosiologi, pemasaran, dan riset pasar.

Tujuan Utama FA

- **Mengidentifikasi struktur faktor (*Factor Structure*):** Menentukan berapa banyak faktor laten yang ada dan variabel mana yang terkait dengan faktor mana.
- **Mereduksi dimensi:** Menggantikan banyak variabel asli dengan sejumlah kecil faktor laten tanpa kehilangan informasi penting.
- **Memahami hubungan:** Memberikan wawasan tentang mengapa variabel-variabel tertentu berkorelasi.
- **Membangun skala/indeks:** Mengembangkan skor faktor untuk setiap individu, yang dapat digunakan dalam analisis lebih lanjut (misalnya, *clustering* atau regresi).

Apa itu Faktor Laten (Latent Factors)?

Bayangkan kita melakukan survei kepuasan pelanggan dengan banyak pertanyaan, seperti:

- "Apakah Anda puas dengan kualitas produk?"
- "Apakah produk ini tahan lama?"
- "Apakah produk ini sesuai dengan deskripsi?"
- "Apakah harga produk ini sepadan?"
- "Apakah layanan purna jualnya responsif?"
- "Apakah staf penjualan ramah?"

→ Secara terpisah, pertanyaan ini adalah 6 variabel.

Mungkin ada beberapa "tema" atau "konstruk" yang lebih besar yang memengaruhi jawaban. Misalnya:

- Kepuasan dengan kualitas dan ketahanan mungkin dipengaruhi oleh **Faktor Laten "Kualitas Produk"**.
- Kepuasan dengan harga dan layanan purna jual mungkin dipengaruhi oleh **Faktor Laten "Nilai & Dukungan"**.

Faktor-faktor laten **tidak dapat diukur secara langsung**. FA membantu kita mengidentifikasi dan mengukur seberapa besar pengaruh setiap faktor laten ini terhadap variabel-variabel yang kita amati.

Model Matematis FA

Secara matematis, **Factor Analysis (FA)** memodelkan setiap **observed variable** X_i sebagai kombinasi linier dari **faktor-faktor laten** F_j , ditambah **komponen error unik** e_i yang hanya dimiliki oleh variabel tersebut.

$$X_i = L_{i1}F_1 + L_{i2}F_2 + \dots + L_{ik}F_k + e_i$$

Keterangan:

- X_i : Variabel teramati ke- i
(contoh: "Apakah Anda puas dengan kualitas produk?")
- F_j : Faktor laten ke- j
(contoh: Faktor umum seperti "Kualitas Produk" atau "Harga")
- L_{ij} : **Factor Loading**, yaitu koefisien atau bobot yang menunjukkan kekuatan hubungan antara X_i dan F_j . Nilainya biasanya berkisar antara **-1 dan 1** (semakin besar absolutnya, semakin kuat hubungan).
- e_i : **Unique Variance** (error unik), yaitu bagian dari variasi X_i yang **tidak dijelaskan oleh faktor laten**, bisa berasal dari error pengukuran atau karakteristik unik dari X_i .

Intuisi FA: Step-by-step

Kita akan menggunakan data dummy dari survey dengan topik "**Online Shopping Experience**".

	Kemudahan_Navigasi_Website	Kecepatan>Loading_Page	Estetika_Desain_Website	Pilihan_Produk_Lengkap	Ketersediaan_Stok	Harga_Kompetitif	Proses_Pembayaran_Mudah	Layanan_Pelanggan_Responsif
0	1.000000	1.0	1.0	3.125	5.0	3.0	3.333333	4.0
1	3.176471	2.0	1.0	1.000	1.0	1.0	2.333333	5.0
2	3.823529	5.0	2.0	2.000	2.0	3.0	2.333333	1.0
3	1.411765	2.0	3.0	2.625	2.0	4.0	3.333333	4.0
4	3.176471	2.0	4.0	2.000	2.0	4.0	4.333333	3.0


Step 1: Standardisasi Data/Data Preparation

Seperti PCA, FA juga sensitif terhadap skala fitur. Oleh karena itu, **standardisasi data** (mengubah data sehingga memiliki rata-rata 0 dan standar deviasi 1) adalah langkah awal yang sangat penting.

	Kemudahan_Navigasi_Website	Kecepatan>Loading_Page	Estetika_Desain_Website	Pilihan_Produk_Lengkap	Ketersediaan_Stok	Harga_Kompetitif	Proses_Pembayaran_Mudah	Layanan_Pelanggan_Responsif
0	-1.791921	-1.520723	-1.365804	0.038640	1.444907	0.069843	0.350303	0.65158
1	0.150683	-0.826329	-1.365804	-1.893373	-1.268533	-1.327018	-0.641120	1.35982
2	0.728214	1.256854	-0.692994	-0.984190	-0.590173	0.069843	-0.641120	-1.47314
3	-1.424401	-0.826329	-0.020184	-0.415951	-0.590173	0.768273	0.350303	0.65158
4	0.150683	-0.826329	0.652626	-0.984190	-0.590173	0.768273	1.341725	-0.05665

Step 2: Menghitung Correlation Matrix

FA beroperasi pada **matriks korelasi** antar variabel. Matriks ini menunjukkan seberapa kuat dan arah setiap pasangan variabel bergerak bersama. Adanya korelasi adalah prasyarat dasar untuk FA.



Step 3: Uji Kecukupan Sampling (Sampling Adequacy Test)

Sebelum melangkah lebih jauh, kita harus memastikan bahwa data kita **cukup cocok untuk analisis faktor**. Jika tidak, hasil FA mungkin tidak valid.

- **Kaiser–Meyer–Olkin (KMO) Measure of Sampling Adequacy:** Mengukur seberapa baik data Anda untuk FA. Nilai KMO bervariasi dari 0 hingga 1.
 - **KMO > 0.6** (lebih baik > 0.7 atau > 0.8) umumnya dianggap sebagai indikasi kecukupan.
 - KMO juga bisa dihitung per variabel.
- **Bartlett's Test of Sphericity:** Menguji hipotesis nol bahwa matriks korelasi adalah matriks identitas (yaitu, tidak ada korelasi antar variabel).
 - Jika **p-value < 0.05**, kita menolak hipotesis nol, yang berarti ada korelasi yang cukup signifikan antar variabel, sehingga FA sesuai.

Step 4: Ekstraksi Faktor Awal (Initial Factor Extraction)

Algoritma FA mencoba mengekstrak sejumlah faktor (konstruk laten) yang dapat menjelaskan sebagian besar kovarians dalam *observed variable*. Ada beberapa metode ekstraksi:


- **Principal Factor Analysis (PFA):** Mirip dengan PCA, tetapi fokus pada *common variance* daripada total varians.
- **Maximum Likelihood (ML):** Mengasumsikan data terdistribusi normal multivariat dan mencari faktor yang paling mungkin menjelaskan matriks korelasi.

Beberapa kriteria untuk menentukan **berapa banyak faktor yang akan diekstraksi**:

- **Kriteria Kaiser (*Eigenvalue* > 1):** Pertahankan faktor-faktor yang memiliki *eigenvalue* lebih besar dari 1. *Eigenvalue* ini mewakili jumlah varians yang dijelaskan oleh faktor tersebut.
- **Scree Plot:** Visualisasi *eigenvalue* yang diurutkan menurun. Cari "siku" (*elbow point*) pada plot, di mana penurunan *eigenvalue* mulai melambat secara signifikan. Ini menunjukkan titik di mana penambahan faktor baru hanya menjelaskan sedikit varians tambahan.
- **Berdasarkan teori (*domain knowledge*):** Jika sudah memiliki hipotesis tentang berapa banyak faktor yang seharusnya ada berdasarkan teori di bidang tertentu.

Step 4: Ekstraksi Faktor Awal (Initial Factor Extraction)

Eigenvalues dari Matriks Korelasi (Unrotated Factors):
 [1.7375687 1.59468424 1.41041273 1.1300242 0.87164896 0.56714248
 0.41234489 0.27617381]



Memilih 3 faktor berdasarkan Scree Plot dan/atau Kriteria Kaiser.


--- FA Model (Tanpa Rotasi) ---

Factor Loadings (Awal, sebelum rotasi):

	Faktor1	Faktor2	Faktor3
Kemudahan_Navigasi_Website	0.862112	0.197524	-0.127543
Kecepatan>Loading_Page	0.893894	0.201238	-0.102727
Estetika_Desain_Website	-0.064250	0.189471	0.362762
Pilihan_Produk_Lengkap	0.359097	-0.697641	0.425728
Ketersediaan_Stok	0.161785	-0.804392	0.340718
Harga_Kompetitif	0.185014	0.098779	-0.128773
Proses_Pembayaran_Mudah	0.034046	0.414728	0.714868
Layanan_Pelanggan_Responsif	0.025365	0.404680	0.653487

Step 5: Rotasi Faktor (Factor Rotation)

- Setelah faktor diekstraksi, *factor loadings* awal (tanpa rotasi) seringkali sulit diinterpretasikan. Banyak variabel mungkin memiliki *loading* sedang pada beberapa faktor, yang membuat "makna" setiap faktor menjadi kabur.
- **Rotasi** bertujuan untuk mencapai **struktur sederhana** (*simple structure*): setiap variabel memiliki *loading* tinggi pada satu faktor dan *loading* mendekati nol pada faktor lainnya. Ini sangat meningkatkan interpretasi.



Step 6: Menghitung Varians yang Dijelaskan (Communality & Unique Variance)

FA menjelaskan bagaimana varians total setiap variabel terbagi menjadi:

- **Common Variance (Communality – h^2):** Ini adalah proporsi varians setiap variabel yang dijelaskan oleh **semua faktor** yang diekstraksi. Nilai h^2 berkisar antara 0 hingga 1. *Communality* yang tinggi berarti variabel tersebut dijelaskan dengan baik oleh faktor-faktor yang diekstraksi.
- **Unique Variance (Uniqueness – u^2):** Bagian varians variabel yang **tidak dijelaskan oleh faktor-faktor umum**. Ini adalah varians spesifik untuk variabel itu sendiri ditambah *error* pengukuran. Secara sederhana, $u^2 = 1 - h^2$ (untuk data terstandarisasi).

Varians yang dijelaskan oleh setiap faktor (setelah rotasi):

Common Variance per faktor: [1.7163556 1.57099894 1.45531113]

Proporsi Varians per faktor: [0.21454445 0.19637487 0.18191389]

Kumulatif Proporsi Varians: [0.21454445 0.41091932 0.59283321]

Communalities (Varians yang dijelaskan oleh faktor per variabel):

Kemudahan_Navigasi_Website	0.798519
Kecepatan>Loading_Page	0.850095
Estetika_Desain_Website	0.171624
Pilihan_Produk_Lengkap	0.796899
Ketersediaan_Stok	0.789310
Harga_Kompetitif	0.060570
Proses_Pembayaran_Mudah	0.684195
Layanan_Pelanggan_Responsif	0.591454

Unique Variances (Varians tidak dijelaskan oleh faktor per variabel):

Kemudahan_Navigasi_Website	0.201481
Kecepatan>Loading_Page	0.149905
Estetika_Desain_Website	0.828376
Pilihan_Produk_Lengkap	0.203101
Ketersediaan_Stok	0.210690
Harga_Kompetitif	0.939430
Proses_Pembayaran_Mudah	0.315805
Layanan_Pelanggan_Responsif	0.408546

Interpretasi Model & Hasil Factor Analysis

1. Interpretasi *Factor Loadings* (Setelah Rotasi):

- a. Lihatlah matriks *factor loadings* yang sudah dirotasi.
- b. Fokus pada *loading* yang tinggi (nilai absolut, misal > 0.4 atau > 0.5) untuk setiap variabel.
- c. Kelompokkan variabel-variabel yang memiliki *loading* tinggi pada faktor yang sama.
- d. Berdasarkan variabel-variabel yang mengelompok tersebut, **berikan nama deskriptif** yang bermakna untuk setiap faktor. Nama ini harus mewakili konsep laten yang dijelaskan oleh kelompok variabel tersebut.
- e. Perhatikan juga *loading* negatif. Jika 'Variabel X' memiliki *loading* negatif tinggi pada 'Faktor Y', itu berarti 'Variabel X' cenderung bergerak berlawanan arah dengan 'Faktor Y'.

Interpretasi Model & Hasil Factor Analysis

2. Periksa *Communalities*:

- a. Tinjau nilai *communality* untuk setiap variabel.
- b. *Communality* yang tinggi (mendekati 1) berarti sebagian besar varians variabel tersebut dijelaskan oleh faktor-faktor yang diekstraksi. Ini menunjukkan bahwa variabel tersebut terwakili dengan baik oleh model faktor.
- c. *Communality* yang sangat rendah (< 0.2 atau 0.3) mungkin mengindikasikan bahwa variabel tersebut tidak dijelaskan dengan baik oleh faktor-faktor yang ada, atau mungkin bukan bagian dari struktur faktor yang ditemukan. Pertimbangkan untuk menghapus variabel tersebut dari analisis atau mengeksplorasi lebih banyak faktor.

Interpretasi Model & Hasil Factor Analysis

3. Tinjau *Unique Variances*:

Ini adalah kebalikan dari *communality*. *Unique variance* yang tinggi berarti banyak varians variabel tersebut tidak dijelaskan oleh faktor-faktor umum.

1. Evaluasi Jumlah Faktor:

Setelah interpretasi, tanyakan pada diri Anda: apakah jumlah faktor yang dipilih (misal dari *Scree Plot* atau kriteria Kaiser) menghasilkan interpretasi yang paling masuk akal dan berguna? Terkadang, Anda mungkin perlu mencoba jumlah faktor yang berbeda untuk menemukan solusi yang paling mudah diinterpretasikan.



Hands-On!

A large, stylized graphic on the left side of the slide. It consists of a blue circular shape with a large orange circle in the center, and a smaller blue circle above it with a smaller orange circle in the center, resembling a person or a character.

**Terima
Kasih!**