

Exploring Clustering Techniques with Python

Batch 33B | Bootcamp Data Science & Data Analyst





Nikmatun Aliyah Salsabila

Mentor

Data Scientist

LinkedIn:

[linkedin.com/in/nasalsabila](https://www.linkedin.com/in/nasalsabila)


- **Data Scientist**
at Multidaya Teknologi Nusantara
- **Data Analyst**
at Airy Nest Indonesia

On the left side of the slide, there are three overlapping geometric shapes: a large black parallelogram at the top, a medium-sized light orange parallelogram in the middle, and a smaller dark orange parallelogram at the bottom. All shapes are slanted to the right.

Intro to Clustering

Apa itu Clustering?

Clustering adalah teknik *Unsupervised Learning* untuk mengelompokkan sekumpulan data ke dalam grup-grup (*clusters*) berdasarkan kemiripannya. Tujuannya adalah agar data dalam satu cluster sangat mirip satu sama lain, dan sangat berbeda dengan data di cluster lain.



Contoh Penerapan

- **Bisnis:** Mengelompokkan pelanggan berdasarkan perilaku pembelian, demografi, atau interaksi mereka untuk strategi marketing yang lebih tertarget.
- **Analisis Medis:** Mengelompokkan pasien dengan gejala serupa untuk mengidentifikasi pola penyakit.
- **Pengelompokan dokumen:** Mengkategorikan artikel berita, email, atau dokumen ke dalam topik-topik tertentu.
- **Deteksi Anomali:** Data yang tidak masuk ke dalam cluster manapun dapat diidentifikasi sebagai anomali atau *outlier*.

Konsep Jarak (Distance Metrics)

Inti dari *clustering* adalah mengukur kemiripan antar objek. Kemiripan ini biasanya diukur dengan **jarak (distance)**. Semakin kecil jaraknya, semakin mirip objek tersebut. Beberapa metrik jarak umum:

Euclidean Distance: Paling umum digunakan, menghitung jarak garis lurus antara dua titik dalam ruang Euclidean. Untuk dua titik $p=(p_1, p_2, \dots, p_n)$ dan $q=(q_1, q_2, \dots, q_n)$, maka:

$$d(p, q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \dots + (p_n - q_n)^2}$$


Manhattan Distance / City Block Distance: Menghitung jumlah perbedaan absolut antara koordinat. Bayangkan bergerak di grid kota, hanya bisa bergerak secara horizontal atau vertikal.

$$d(p, q) = |p_1 - q_1| + |p_2 - q_2| + \dots + |p_n - q_n|$$

Cosine Similarity: Mengukur sudut antara dua vektor. Lebih cocok untuk data teks atau data dimensi tinggi lainnya di mana magnitude vektor kurang penting daripada arahnya.

$$similarity = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

Konsep Jarak (Distance Metrics)



Euclidean Distance: 5.00
Manhattan Distance: 7.00

Misal, $P = (1, 2)$ dan $Q = (4, 6)$. Maka,

Euclidean Distance

$$d(P, Q) = \sqrt{(4 - 1)^2 + (6 - 2)^2}$$

$$d(P, Q) = \sqrt{(3)^2 + (4)^2}$$

$$d(P, Q) = \sqrt{9 + 16} \quad d(P, Q) = \sqrt{25}$$

$$d(P, Q) = 5$$

Manhattan Distance

$$d(P, Q) = |4 - 1| + |6 - 2|$$

$$d(P, Q) = |3| + |4|$$

$$d(P, Q) = 3 + 4$$

$$d(P, Q) = 7$$



Jenis & Metode Clustering

Metode	Ide Utama	Karakteristik	Kelebihan	Kekurangan
Centroid-based (Contoh: K-Means)	Mengelompokkan berdasarkan kedekatan ke centroid	- Cluster bulat/konveks - Hard assignment - Butuh jumlah k	- Cepat dan efisien - Mudah diinterpretasi	- Sensitif outlier - Tak cocok untuk bentuk kompleks - Butuh k
Density-based (Contoh: DBSCAN)	Kelompok berdasar kepadatan titik data	- Bentuk arbitrer - Deteksi outlier - Tak butuh k	- Deteksi outlier - Cocok untuk bentuk kompleks	- Sulit jika kepadatan bervariasi - Parameter sensitif
Hierarchical (Contoh: Agglomerative, Divisive)	Membangun pohon klaster (dendrogram)	- Struktur hierarkis - Tak butuh k awal - Bisa divisualisasi	- Tidak butuh k di awal - Menjelaskan struktur data	- Komputasi mahal - Tak cocok untuk data overlap besar
Distribution-based (Contoh: GMM)	Klaster = distribusi statistik (Gaussian)	- Soft assignment - Probabilistik - Tumpang tindih dimungkinkan	- Fleksibel bentuk cluster - Menangani overlap	- Asumsi distribusi - Komputasi lebih kompleks
Spectral Clustering	Mengubah ke bentuk graph & gunakan nilai eigen	- Cocok untuk bentuk tak teratur - Graph partitioning - Gunakan reduksi dimensi	- Tangani bentuk kompleks - Kuat terhadap noise	- Komputasi mahal - Parameter rumit

A large black parallelogram is positioned on the left side of the slide. Below it, two overlapping parallelograms in shades of orange and yellow are also positioned on the left, partially overlapping the black shape.

Cluster Analysis: K-Means Clustering

K-Means



Intuisi Sederhana: “Masalah Penempatan Kantor Pos”

Bayangkan kita harus menempatkan K kantor pos (μ_k) di sebuah kota dengan banyak rumah (x_n). Tujuannya adalah agar jarak rata-rata dari setiap rumah ke kantor pos terdekatnya minimal.

1. **Tebakan awal:** Letakkan K kantor pos secara acak.
2. **Assignment/E-Step:** Setiap rumah mendaftar ke kantor pos terdekat. Ini membentuk "wilayah layanan" atau *cluster*.
3. **Update/M-Step:** Pindahkan setiap kantor pos ke pusat dari semua rumah yang dilayaninya.
4. **Ulangi:** Proses 2 dan 3 diulangi terus. Rumah-rumah mungkin akan mendaftar ke kantor pos yang berbeda setelah kantor posnya pindah, dan pusat wilayah pun akan bergeser lagi.
5. **Selesai:** Proses berhenti saat posisi kantor pos tidak lagi berubah secara signifikan (konvergen).



Algoritma K-Means: Expectation-Maximization (E-M)

1. **Pilih jumlah cluster K:** Ini adalah parameter kunci dan seringkali ditentukan sebelumnya atau ditemukan menggunakan metode seperti "Elbow Method".
2. **Inisialisasi Centroid:**
 - a. Secara acak pilih K titik data dari dataset sebagai centroid awal.
 - b. Atau, gunakan metode yang lebih canggih seperti **K-Means++** untuk inisialisasi yang lebih baik, yang memilih centroid awal secara strategis untuk menyebar.
3. **Iterasi (Loop):** Ulangi sampai konvergensi (centroid tidak banyak bergerak atau perubahan minim):
 - a. **Assignment Step (Langkah Penugasan - E-Step):** Untuk setiap titik data x_i , hitung jaraknya ke setiap centroid c_j . Tugaskan x_i ke cluster dengan centroid terdekat.


$$cluster(x_i) = \arg \min_j ||x_i - c_j||^2$$

- b. **Update Step (Langkah Pembaruan - M-Step):** Untuk setiap cluster j , hitung ulang centroid c_j sebagai rata-rata (mean) dari semua titik data yang ditugaskan ke cluster j .

$$c_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$$

di mana C_j adalah set titik data yang ditugaskan ke cluster j .

Algoritma K-Means: Expectation-Maximization (E-M)



A large black parallelogram is positioned on the left side of the slide. Below it, two overlapping parallelograms in shades of orange and yellow are also positioned on the left, creating a layered, abstract geometric design.

Evaluasi dan Interpretasi


Metrik Intrinsik (Internal Evaluation)

Inertia (Within-Cluster Sum of Squares - WCSS)

- Inertia mengukur **kekompakan (compactness)** atau **kepadatan** cluster. Secara matematis, Inertia adalah jumlah kuadrat jarak antara setiap titik data dan centroid cluster tempat titik data tersebut berada, dijumlahkan untuk semua kluster.

$$WCSS = \sum_{j=1}^K \sum_{x \in C_j} \|x - c_j\|^2$$

- Semakin rendah nilai Inertia, semakin baik** karena menunjukkan bahwa titik-titik data dalam setiap kluster lebih dekat dengan centroidnya, mengindikasikan kluster yang lebih padat dan kohesif.
- Kelemahan: Inertia akan **selalu menurun** seiring bertambahnya jumlah kluster (K). Oleh karena itu, Inertia **tidak bisa digunakan sendiri** untuk menentukan K optimal karena akan selalu menyarankan K sebanyak mungkin. Kita tidak bisa menggunakannya untuk mengatakan "model K=5 lebih baik dari K=3".
- Sangat berguna untuk **menentukan jumlah K yang optimal** melalui **Elbow Method**. Kita mencari titik "siku" di mana penambahan cluster baru tidak lagi memberikan penurunan Inertia yang signifikan/penurunan Inertia mulai melambat.



Metrik Intrinsik (Internal Evaluation)

Silhouette Score (Koefisien Silhouette)

- Silhouette Score mengukur **seberapa baik setiap titik data ditempatkan dalam clusternya**.
- **Skor berkisar dari -1 hingga +1.**
 - **+1:** Clustering sangat baik. Titik data sangat dekat dengan titik lain di clusternya (kohesi tinggi) dan sangat jauh dari cluster tetangga (separasi tinggi).
 - **0:** Titik data berada di perbatasan antara dua cluster.
 - **-1:** Clustering buruk. Titik data kemungkinan besar salah ditempatkan di cluster yang salah.
- **Cara kerja (intuisi):** Untuk setiap titik data, ia menghitung dua nilai:
 - a = Jarak rata-rata ke semua titik lain dalam **cluster yang sama**.
 - b = Jarak rata-rata ke semua titik dalam **cluster tetangga terdekat**.
 - Silhouette Score untuk satu titik:

$$s = \frac{b - a}{\max(a, b)}$$

Skor total adalah rata-rata dari semua skor s untuk semua titik data.

Kesimpulan:

Gunakan **Elbow Method (Inertia)** untuk **menemukan K** , lalu gunakan **Silhouette Score** untuk **mengevaluasi kualitas akhir** dari model dengan K yang terpilih.

Interpretasi – Dari Cluster ke Insight Bisnis



Membuat *cluster* hanyalah setengah dari pekerjaan. Bagian terpenting adalah menerjemahkan cluster tersebut menjadi *insights* yang dapat ditindaklanjuti.

1. **Visualisasi:** Plot hasil cluster. Ini adalah cara tercepat untuk memahami struktur data.
2. **Analisis centroid:** Periksa nilai centroid untuk setiap cluster. Centroid mewakili "prototype" atau "rata-rata" dari anggota cluster tersebut.
3. **Pembuatan persona:** Beri nama atau "persona" yang deskriptif untuk setiap cluster berdasarkan karakteristiknya. Contoh: "Pelanggan Loyal Kaya Raya", "Pemburu Diskon", "Mahasiswa Impulsif".
4. **Rekomendasi strategi:** Berdasarkan persona tersebut, rumuskan strategi bisnis yang spesifik. Misalnya, kirim penawaran premium ke cluster "Loyal Kaya Raya" dan kupon diskon ke cluster "Pemburu Diskon".



Hands-On!

A large, stylized graphic on the left side of the slide. It consists of a blue outline of a person's head and shoulders. Inside the head is a series of concentric circles: a small light orange circle, a medium orange circle, and a large blue circle. The body is a large blue circle containing a large orange circle with a smaller light orange circle in the center.

**Terima
Kasih!**